4장. 처리율 제한 장치의 설계

Created	@September 29, 2022 1:02 PM
Progress	DONE

학습 TODO list

- [ ] DoS(Denial of Service) 공격
- [ ] 자원 고갈(resource starvation)
- [ ] API 게이트웨이
- [ ] API 엔드포인트

4.1. 1단계: 문제 이해 및 설계 범위 확정
4.2. 2단계: 개략적 설계안 제시 및 동의 구하기
    4.2.1. 처리율 제한 장치의 위치
    4.2.2. 처리율 제한 알고리즘
    4.2.3. 개략적인 아키텍처
4.3. 3단계: 상세 설계
    4.3.1. 처리율 제한 규칙
    4.3.2. 처리율 한도 초과 트래픽 처리
    4.3.3. 상세 설계
    4.3.4. 분산 환경에서의 처리율 제한 장치의 구현
4.4. 4단계: 마무리

> *네트워크 시스템에서 처리율 제한 장치(rate limiter)는 클라이언트 또는 서비스가 보내는 트래픽의 처리율(rate)을 제어하기 위한 장치다.*

- HTTP 통신 예: `처리율 제한 장치`가 ***특정 기간 내에 전송되는 클라이언트의 요청 횟수를 제한함***
    - API 요청 횟수가 제한 `처리율 제한 장치`에 정의된 임계치(threshold)를 넘어서면 추가로 도달한 모든 호출은 처리가 중단(block)됨
    - ex. 사용자는 초당 2회 이상 새 글을 올릴 수 없다.
    - ex. 같은 IP 주소로는 하루에 10개 이상의 계정을 생성할 수 없다.
    - ex. 같은 디바이스로는 주당 5회 이상 리워드(reward)를 요청할 수 없다.

> *API에 처리율 제한 장치를 두면 좋은 점*

- `DoS(Denial of Service) 공격`에 의한 `자원 고갈(resource starvation)`을 방지할 수 있음
- 비용 절감
    - 서버를 많이 두지 않아도 되고, 우선순위가 높은 API에 더 많은 자원을 할당할 수 있음
    - 제3자(third-party) API에 사용료를 지불하고 있는 회사들의 경우 과금 기준에 따라 API 요청 횟수를 제한할 수 있음
    - `서버 과부하`를 막음: 봇(bot)에서 오는 트래픽이나 사용자의 잘못된 이용 패턴으로 유발된 트래픽을 걸러냄

> *설계 예시*
> *1단계: 문제 이해 및 설계 범위 확정*
> *2단계: 개략적 설계안 제시 및 동의 구하기*
> *3단계: 상세 설계*
> *4단계: 마무리*

4.1. 1단계: 문제 이해 및 설계 범위 확정

👩‍💻 어떤 종류의 처리율 제한 장치를 설계해야 하나요? 클라이언트 측 제한 장치입니까, 아니면 서버 측 제한 장치입니까?

👨‍💻 좋은 질문이에요. 서버측 API를 위한 장치를 설계한다고 가정합시다.

👩‍💻 어떤 기준을 사용해서 API 호출을 제어해야 할까요? IP 주소를 사용해야 하나요? 아니면 사용자 ID? 아니면 생각하는 다른 어떤 기준이 있습니까?

👨‍💻 다양한 형태의 제어 규칙(throttling rules)을 정의할 수 있도록 하는, 유연한 시스템이어야 합니다.

👩‍💻 시스템의 규모는 어느 정도여야 할까요? 스타트업 정도 회사를 위한 시스템입니까 아니면 사용자가 많은 큰 기업을 위한 제품입니까?

👨‍💻 설계할 시스템은 대규모 요청을 처리할 수 있어야 합니다.

👩‍💻 시스템이 분산 환경에서 동작해야 하나요?

👨‍💻 그렇습니다.

👩‍💻 이 처리율 제한 장치는 독립된 서비스입니까 아니면 애플리케이션 코드에 포함될 수도 있습니까?

👨‍💻 그 결정은 본인이 내려주시면 되겠습니다.

👩‍💻 사용자의 요청이 처리율 제한 장치에 의해 걸러진 경우 사용자에게 그 사실을 알려야 하나요?

👨‍💻 그렇습니다.

- **시스템 요구사항 요약**
  - 설정된 처리율을 초과하는 요청은 정확하게 제한한다.
  - 낮은 응답시간: 이 처리율 제한 장치는 HTTP 응답시간에 나쁜 영향을 주어서는 곤란하다.
  - 가능한 한 적은 메모리를 써야 한다.
  - 분산형 처리율 제한(distributed rate limiting): 하나의 처리율 제한 장치를 여러 서버나 프로세스에서 공유할 수 있어야 한다.

- 예외 처리: 요청이 제한되었을 때는 그 사실을 사용자에게 분명하게 보여주어야 한다.
- 높은 결함 감내성(fault tolerance): 제한 장치에 장애가 생기더라도 전체 시스템에 영향을 주어서는 안된다.

4.2. 2단계: 개략적 설계안 제시 및 동의 구하기

> *기본적인 클라이언트-서버 통신 모델을 사용하여 설계해보자.*

4.2.1. 처리율 제한 장치의 위치

- 클라이언트 측에 둘 경우: 클라이언트 요청은 위변조가 가능하고 모든 클라이언트의 구현을 통제하는 것은 어려움 → ***일반적으로 클라이언트에서는 처리율 제한을 안정적으로 걸 수 없음***
- 서버 측에 둘 수 있음
- `처리율 제한 미들웨어(middleware)`를 만들어 해당 미들웨어가 API 서버로 가는 요청을 통제할 수 있음
  - ex. API 서버의 처리율이 초당 2개의 요청으로 제한된 상황에서, 클라이언트가 3번째 요청을 같은 초 범위 내에서 전송하였을 경우 → 앞 두 요청은 API 서버로 전송되고 세 번째 요청은 `처리율 제한 미들웨어(middleware)`에 의해 가로막히고 클라이언트로 `HTTP 상태코드 429`가 반환됨
  - ex. `클라우드 마이크로서비스`의 경우 보통 `API 게이트웨이(gateway)` 컴포넌트에 `처리율 제한 장치`가 구현됨

👩‍💻 `처리율 제한 장치`의 위치 설계 시 고려 사항

- 프로그래밍 언어, 캐시 서비스 등 현재 사용하고 있는 기술 스택 점검
  - 현재 사용하는 프로그래밍 언어가 서버 측 구현을 지원하기 충분할 정도로 효율이 높은가?
- 사업 필요에 맞는 처리율 제한 알고리즘 찾기
  - 서버 측에서 모든 것을 구현하는가? → 알고리즘을 자유롭게 선택
  - 제3 사업자가 제공하는 게이트웨이를 사용하기로 했는가? → 선택지 제한
- 설계가 마이크로서비스에 기반하고 사용자 인증이나 IP 허용목록 관리 등을 처리하기 위한 API 게이트웨이가 있는가? → 처리율 제한 기능을 게이트웨이에 포함
- 처리율 제한 장치를 구현할 인력이 충분한가? → 상용 API 게이트웨이 고려

4.2.2. 처리율 제한 알고리즘

- `토큰 버킷(token bucket) 알고리즘`: 아마존, 스트라이프가 API 요청을 통제(throttle)하기 위해 사용함
  - 동작 원리

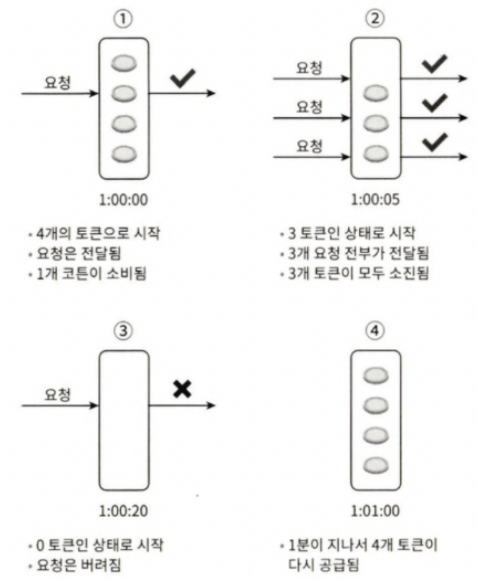

처리 제한 로직 작동 예: *토큰 공급률(refill rate) = 분당 4*

- 토큰 버킷: 지정된 용량을 갖는 컨테이너 → 사전 설정된 양의 토큰이 주기적으로 채워짐
  - 토큰이 꽉 찬 버킷에는 더 이상의 토큰이 추가되지 않음 → 버킷이 가득 차면 추가로 공급된 토큰은 버려짐 (overflow)
- 각 요청은 처리될 때마다 하나의 토큰을 사용함 → 요청이 도착하면 버킷에 충분한 토큰이 있는지 검사함

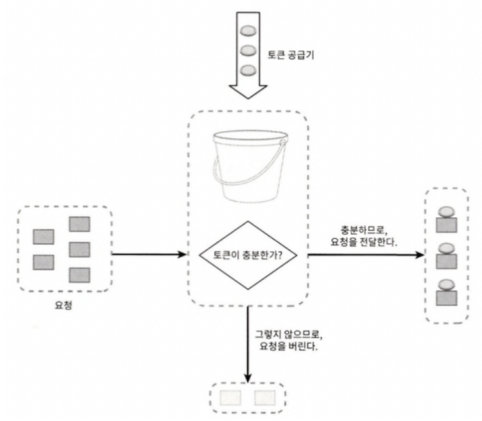

- 충분한 토큰이 있는 경우: 버킷에서 토큰 하나를 꺼낸 후 요청을 시스템에 전달
- 충분한 토큰이 없는 경우: 해당 요청은 버려짐(dropped)

◦ 인자(parameter): 버킷 크기, 토큰 공급률(refill rate)

> *버킷의 개수를 정하는 기준: 공급 제한 규칙*

◦ 통상적으로 API 엔드포인트(endpoint)마다 별도의 버킷을 둠

▪ ex. 사용자마다 하루에 한 번만 포스팅 할 수 있고, 친구는 150명까지 추가할 수 있고, 좋아요 버튼을 다섯 번까지만 누를 수 있을 경우 → 3개의 버킷

◦ IP 주소별로 처리율 제한을 적용해야할 경우: IP 주소마다 버킷을 하나씩 할당

◦ 시스템 처리율을 초당 10,000개 요청으로 제한하고 싶을 경우: 모든 요청이 하나의 버킷을 공유

👩‍💻 **장점**

- 구현이 쉬움
- 메모리 사용 측면에서 효율적
- 짧은 시간에 집중되는 트래픽(burst of traffic)도 처리 가능 → 버킷에 남은 토큰이 있기만 하면 요청은 시스템에 전달될 것

👩‍💻 **단점**

- 버킷 크기와 토큰 공급률, 두 인자를 적절하게 튜닝하는 것이 까다로움

- `누출 버킷(leaky bucket) 알고리즘`: 요청 처리율이 고정되어있음, FIFO(First-In-First-Out) 큐로 구현. Shopiphy가 누출 버킷 알고리즘을 사용하여 처리율 제한을 구현하고 있음

◦ 동작 원리

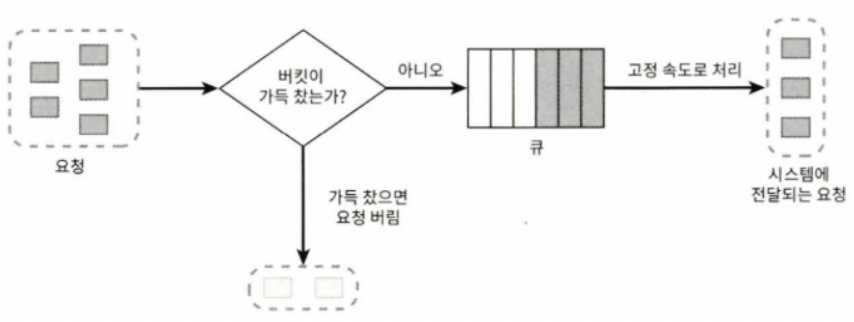

▪ 요청이 도착하면 큐가 가득 차 있는지 확인 → 빈자리가 있는 경우 큐에 요청을 추가함

▪ 큐가 가득 차 있는 경우 새 요청을 버림

▪ 지정된 시간마다 큐에서 요청을 꺼내어 처리함

◦ 인자(parameter): 버킷 크기(=큐 사이즈), 처리율(outflow rate)

🤦 장점

- 큐의 크기가 제한되어 있어 메모리 사용량 측면에서 효율적
- 고정된 처리율을 갖고 있기 때문에 안정적 출력(stable outflow rate)이 필요한 경우에 적합함

🤦 단점

- 단시간에 많은 트래픽이 몰리는 경우 큐에는 오래된 요청들이 쌓이게 되고, 그 요청들을 제때 처리 못하면 최신 요청들은 버려짐
- 두 개 인자를 올바르게 튜닝하기 까다로울 수 있음

- `고정 윈도 카운터(fixed window counter) 알고리즘`
  - 동작 원리

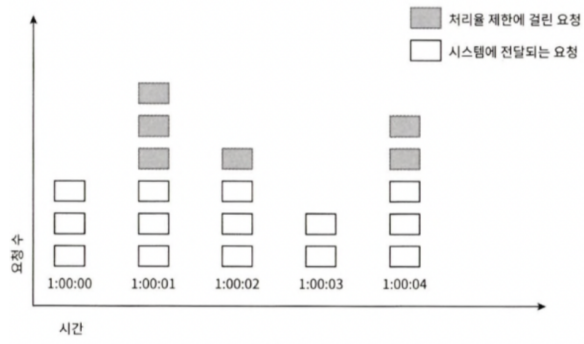

타임라인: 1초, 임계치: 초당 3개의 요청

    - 타임라인(timeline)을 고정된 간격의 윈도(window)로 나누고, 각 윈도마다 카운터(counter)를 붙임
    - 요청이 접수될 때마다 이 카운터 값은 1씩 증가함
    - 카운터의 값이 사전에 설정된 임계치(threshold)에 도달하면 새로운 요청은 새 윈도가 열릴 때까지 버려짐
  - 가장 큰 문제점: 윈도의 경계 부근에 순간적으로 많은 트래픽이 집중될 경우 윈도에 할당된 양보다 더 많은 요청이 처리될 수 있음

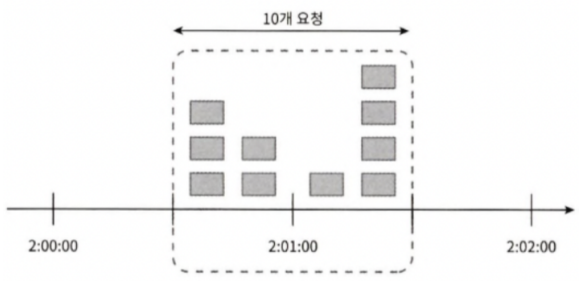

타임라인: 1초, 임계치: 초당 5개의 요청

🤦 장점

- 메모리 효율이 좋음
- 이해하기 쉬움
- 윈도가 닫히는 시점에 카운터를 초기화하는 방식은 특정한 트래픽 패턴을 처리하기에 적합함

🤦 단점

- 윈도 경계 부근에서 일시적으로 많은 트래픽이 몰려드는 경우, 기대했던 시스템의 처리 한도보다 많은 양의 요청을 처리하게 됨

- `이동 윈도 로그(sliding window log) 알고리즘`: 고정 윈도 카운터 알고리즘의 문제점 해결
  - 동작 원리

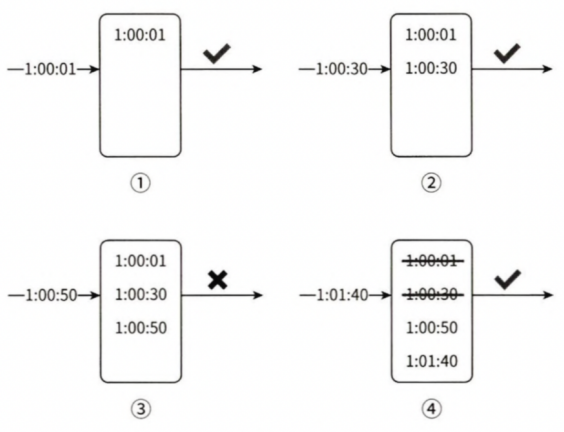

임계치: 분당 2회의 요청 → 1:00:50 요청만 거부됨

- 요청의 타임스탬프(timestamp)를 추적함 → 타임스탬프 데이터는 보통 레디스(Redis)의 정렬 집합(sorted set) 같은 캐시에 보관함
- 새 요청이 오면 만료된 타임스탬프를 제거함
- 새 요청의 타임스탬프를 로그(log)에 추가함
- 로그의 크기가 허용치보다 같거나 작으면 요청을 시스템에 전달함 → 그렇지 않은 경우에는 처리를 거부

👩‍💻 장점

- 어느 순간의 윈도를 보더라도, 허용되는 요청의 개수는 시스템의 처리율 한도를 넘기지 않음

👩‍💻 단점

- 다량의 메모리를 사용함(거부된 요청의 타임스탬프도 보관)

- `이동 윈도 카운터(sliding window counter) 알고리즘` : `고정 윈도 카운터 알고리즘` + `이동 윈도 로그 알고리즘`
  - 동작 원리: 현재 윈도의 요청 수 계산 방법

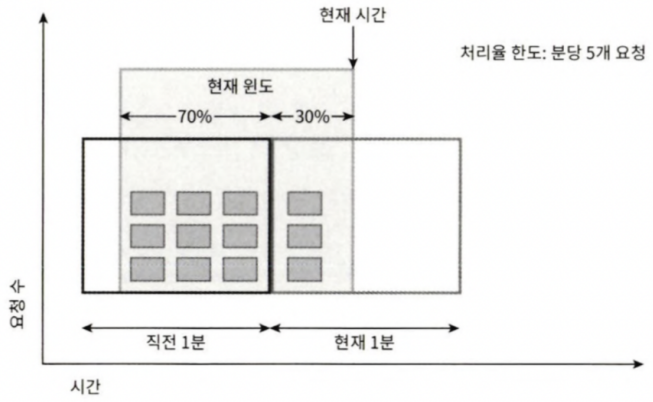

임계치: 분당 7회의 요청

- 현재 1분간의 요청 수 + 직전 1분간의 요청 수 × 이동 윈도와 직전 1분이 겹치는 비율
  - ex. 3 + 5 × 70% = 6.5개 → 현재 1분에서 30% 시점에 도착한 신규 요청은 시스템에 전달될 것

👩‍💻 장점

- 이전 시간대의 평균 처리율에 따라 현재 윈도의 상태를 계산 → 짧은 시간에 몰리는 트래픽에도 잘 대응함
- 메모리 효율이 좋음

👩‍💻 단점

- 직전 시간대에 도착한 요청이 균등하게 분포되어 있다고 가정한 상태에서 추정치를 계산하므로 다소 느슨함

4.2.3. 개략적인 아키텍처

- `처리율 제한 알고리즘`의 기본 아이디어: 얼마나 많은 요청이 접수되었는지를 추적할 수 있는 카운터를 추적 대상별로 두고(사용자별, IP 주소별, API 엔드포인트별, 서비스 단위별 등) 이 카운터의 값이 어떤 한도를 넘어서면 한도를 넘어 도착한 요청은 거부함
  - 카운터 보관 장소: 메모리상에서 동작하는 캐시
    - ex. 레디스(Redis)는 `처리율 제한 장치`를 구현할 때 자주 사용되는 메모리 기반 저장장치로, `INCR`과 `EXPIRE` 두 가지 명령어를 지원함

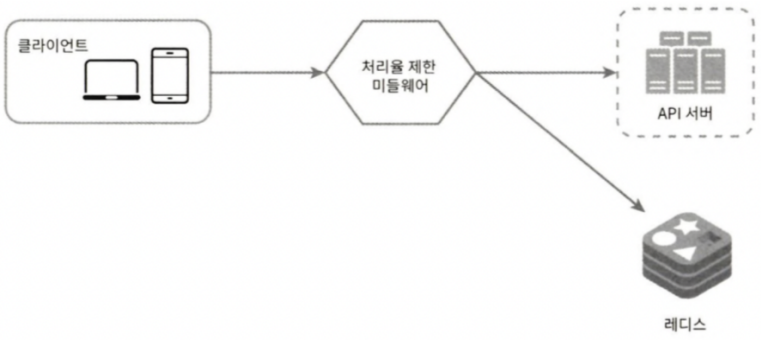

- 클라이언트가 `처리율 제한 미들웨어(rate limiting middleware)`에게 요청을 보냄
- `처리율 제한 미들웨어`: 레디스의 지정 버킷에서 카운터를 가져와서 한도에 도달했는지 아닌지를 검사 → 한도에 도달하면 요청 거부
- 한도에 도달하지 않으면 요청은 API 서버로 전달됨 → `처리율 제한 미들웨어`는 카운터의 값을 증가시킨 후 다시 레디스에 저장함

4.3. 3단계: 상세 설계

👩‍💻 **개략적 설계에서 상세 설계로 넘어가기 위한 고려 사항**

- 처리율 제한 규칙은 어떻게 만들어지고 어디에 저장되는가?
- 처리가 제한된 요청들은 어떻게 처리하는가?

4.3.1. 처리율 제한 규칙

- 리프트(Lyft)의 처리율 제한 오픈소스 컴포넌트 → 설정 파일 형태로 디스크에 저장

```
domain: messaging
descriptors:
  - key: message_type
    value: marketing
    rate_limit:
      unit: day
      requests_per_unit: 5
```

```
domain: auth
descriptors:
  - key: auth_type
    value: login
    rate_limit:
      unit: minute
      requests_per_unit: 5
```

4.3.2. 처리율 한도 초과 트래픽 처리

- 어떤 요청이 한도 제한에 걸리면 API는 `HTTP 429` 응답을 클라이언트에게 보냄
- 한도 제한에 걸린 메시지를 나중에 처리하기 위해 큐에 보관할 수도 있음

> *처리율 제한 장치가 사용하는 HTTP 헤더: 클라이언트가 요청이 처리율 제한에 걸리고 있는지(throttle) 감지하는 방법*

- `처리율 제한 장치`가 클라이언트에 보내는 `HTTP 응답 헤더(response header)`
  - `X-Ratelimit-Remaining`
  - `X-Ratelimit-Limit`

- `X-Ratelimit-Retry-After`

4.3.3. 상세 설계

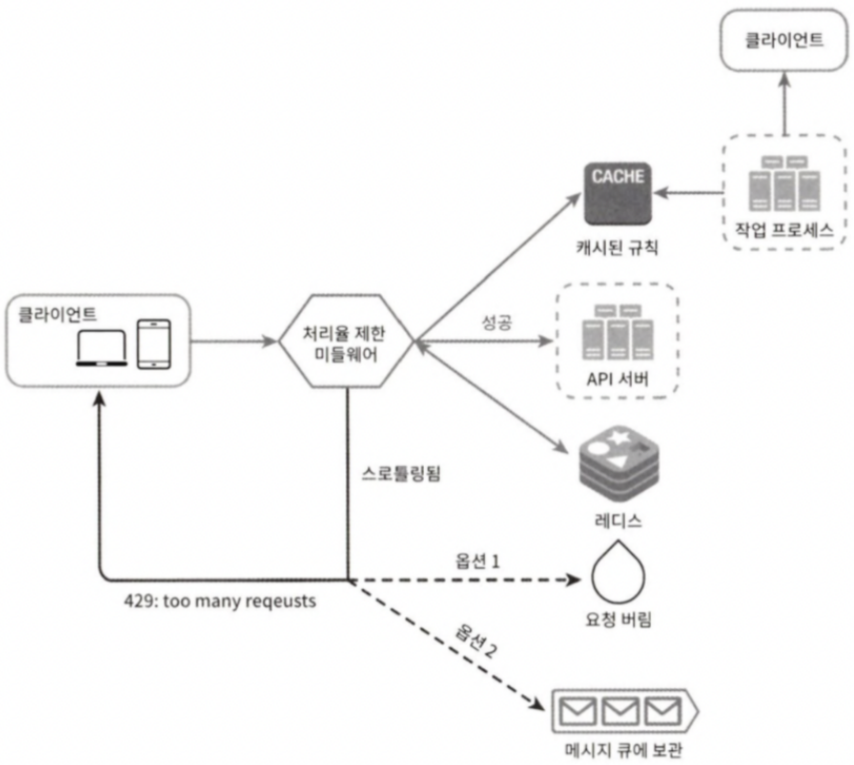

- 처리율 제한 규칙은 디스크에 보관함. 작업 프로세스(workers)는 수시로 규칙을 디스크에서 읽어 캐시에 저장함
- 클라이언트 요청시 `처리율 제한 미들웨어`에서 처리
- `처리율 제한 미들웨어`는 제한 규칙을 캐시에서 가져오고, 카운터 및 마지막 요청의 타임스탬프를 레디스 캐시에서 가져옴
  - 해당 요청이 처리율 제한에 걸리지 않은 경우에는 API 서버로 보냄
  - 해당 요청이 처리율 제한에 걸리면 429 too many requests 에러를 클라이언트에 보냄 → 요청을 버리거나 메시지 큐에 보관

4.3.4. 분산 환경에서의 처리율 제한 장치의 구현

- `처리율 제한 장치`의 동작
  - 레디스에서 카운터의 값을 읽음(counter)
  - counter+1의 값이 임계치를 넘는지 봄
  - 넘지 않으면 레디스에 보관된 카운터 값을 1만큼 증가시킴
- 여러 대의 서버와 병렬 스레드를 지원하도록 시스템을 확장하는데 고려해야할 사항
  - `경쟁 조건(race condition)`: 두 개의 요청을 처리하는 스레드(thread)가 각각 병렬로 counter 값을 읽었을 경우

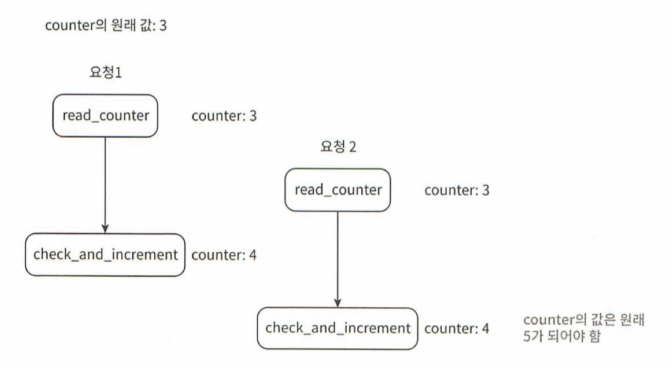

    - 해결 방법
      - ~~`락(lock)`~~ → 시스템 성능을 떨어뜨린다는 문제가 있음
      - `루아 스크립트(Lua script)`
      - `정렬 집합(sorted set)`
  - `동기화(synchronization)`: `처리율 제한 장치` 서버를 여러 대 두게 되면 `동기화`가 필요함

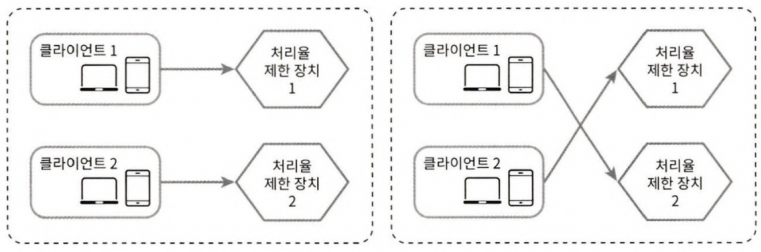

제한 장치 1은 클라이언트 2에 대한 정보가 없음

- ~~`고정 세션(sticky session)`: 같은 클라이언트로부터의 요청은 항상 같은 처리율 제한 장치로 보낼 수 있도록 함~~ → 규모 확장 불가, 유연하지 않음
- 레디스와 같은 `중앙 집중형 데이터 저장소` 사용

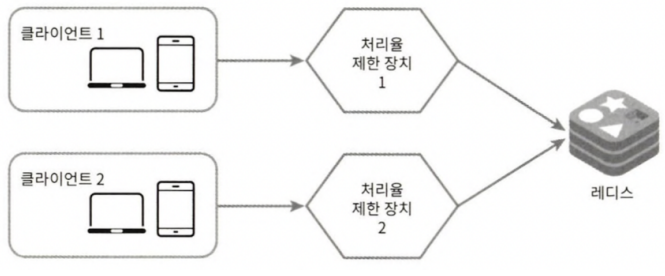

👩‍💻 성능 최적화(개선 가능한 부분들)

- 여러 데이터센터를 지원
  - 데이터센터에서 멀리 떨어진 사용자를 지원하다보면 `지연시간(latency)`가 증가함
  - 대부분의 클라우드 서비스는 세계 곳곳에 에지 서버(edge server)를 심어놓음 → 사용자의 트래픽을 가장 가까운 에지 서버로 전달하여 지연시간을 줄임
- 제한 장치 간에 데이터를 동기화할 때 `최종 일관성 모델(eventual consistency model)`을 사용

👩‍💻 모니터링

- 채택된 `처리율 제한 알고리즘`이 효과적인가?
  - 이벤트 때문에 트래픽이 급증할 때: `처리율 제한 장치`가 비효율적으로 동작하면 해당 트래픽 패턴을 잘 처리할 수 있도록 알고리즘을 바꾸는 것을 고려해야 함 → `토큰 버킷 알고리즘`
- 정의한 `처리율 제한 규칙`이 효과적인가?
  - 처리율 제한 규칙이 너무 빡빡할 경우: 많은 유효 요청이 처리되지 못하고 버려질 것 → 규칙 완화 필요

4.4. 4단계: 마무리

- 경성(hard) 또는 연성(soft) 처리율 제한
  - `경성 처리율 제한`: 요청의 개수는 임계치를 절대 넘어설 수 없음
  - `연성 처리율 제한`: 요청의 개수는 잠시 동안은 임계치를 넘어설 수 있음
- 다양한 계층에서의 처리율 제한
  - 이 책에서 다룬 부분은 `애플리케이션 계층`에서의 `처리율 제한`
  - `IP 주소`에서 `처리율 제한` 방법: Iptables 사용
- 처리율 제한을 회피하는 방법. 클라이언트를 어떻게 설계하는 것이 최선인가?
  - 클라이언트 측 캐시를 사용하여 API 호출 횟수를 줄임
  - 처리율 제한의 임계치를 이해하고, 짧은 시간 동안 너무 많은 메시지를 보내지 않도록 함
  - 예외나 에러를 처리하는 코드를 도입하여 클라이언트가 예외적 상황으로부터 우아하게(gracefully) 복구될 수 있도록 함
  - 재시도(retry) 로직을 구현할 때는 충분한 백오프(back-off) 시간을 둠